

Tema 1

Métodos de Captura de Información

Métodos de captura de información

Origen y calidad de los datos	Organización de los datos	Casos de estudio
<p>Evaluación de calidad:</p> <ul style="list-style-type: none">- Compleitud: Grado en el que los valores se encuentran en un conjunto de datos.- Credibilidad: Nivel de fiabilidad del organismo que proporciona el conjunto de datos.- Consistencia: Grado en el que los datos carecen de contradicciones.- Interpretabilidad: Grado en el que los datos deben ser interpretados por una persona.- Precisión: Nivel de exactitud del valor.	<p>Ficheros planos:</p> <ul style="list-style-type: none">- CSV (comma separated values): RFC 4180. Define un registro por línea y separar los campos por comas.- JSON: RFC 7159 y ECMA-404. Describe objetos encapsulados por llaves y listas por corchetes.- XML: Describo en el estándar XML 1.0 de W3C. Permite almacenar información de forma legible utilizando etiquetas.	Procesamiento de sitio web sobre cursos online Procesamiento de <i>logs</i> de servidor web API de acceso a transacciones bancarias Almacenamiento de información sobre productos en un fichero CSV Representación de información geolocalizada en formato JSON Almacenamiento de información sobre clientes de una base de datos relacional
<p>Niveles de abstracción:</p> <ul style="list-style-type: none">- Datos: Conjunto de hechos discretos y objetivos sobre un evento.- Información: Datos con significado.- Conocimiento: Combinación de información contextualizada, experiencias, valores e intuición.	<p>Bases de datos:</p> <ul style="list-style-type: none">- Conjunto de datos persistentes, utilizados por sistemas de aplicación.- En el modelo Entidad-Relación (E/R) una entidad es cualquier objeto repensado en la BBDD y un vínculo representa relaciones entre ellos.- La unidad básica de almacenamiento es el campo, agrupados en registros y estos en ficheros almacenados.	
<p>Fuentes de datos:</p> <ul style="list-style-type: none">- Captura manual: Encuestas y observaciones.- Análisis de documentos estructurados: estructurados (HTML) y sin formato (lenguaje natural)- Salida de aplicaciones: Logs o bases de datos.- Sensores: Dispositivos de medición.- Datos de acceso público: Gubernamentales y servicios web públicos.	<p>Bases de datos relacionales y SQL</p> <ul style="list-style-type: none">- Los ficheros almacenados se representan en forma de tablas (relaciones), con columnas (campos) y filas (registros).- El estándar SQL define un lenguaje para la consulta y modificación de los datos.- El comando SELECT permite consultar información de tablas.- Los comandos INSERT, UPDATE y DELETE permiten la inserción, edición y eliminación de registros respectivamente.	


Persistencia

- ▶ El método más básico para almacenar datos es mediante el uso del **sistema de ficheros** del sistema operativo.
- ▶ Los ficheros pueden tener un **formato plano**, donde toda la información es legible para una persona; o un **formato binario**, donde la información puede escribirse y leerse de forma directa por una aplicación, pero no puede ser analizada directamente de forma manual.
- ▶ Se habla de dos aproximaciones: la utilización de **ficheros planos**, que son comúnmente utilizados para el almacenamiento y compartición de datos.
- ▶ Las **bases de datos** dan un paso más allá y proporcionan una consistencia en la información y el hecho de poder **consultar y modificar de manera eficiente** un conjunto de datos en específico.

Almacenamiento de datos

- ▶ Sistema de ficheros planos
 - CSV, XML, JSON, TXT...
- ▶ Sistema de ficheros binarios
 - BSON, CLASS...

```
1 CrimeId;OriginalCrimeTypeName;OffenseDate;CallTime;CallDateTime
2 160903280;Assault / Battery;2016-03-30T00:00:00;18:42;2016-03-3
3 160912272;Homeless Complaint;2016-03-31T00:00:00;15:31;2016-03-
4 160912590;Susp Info;2016-03-31T00:00:00;16:49;2016-03-31T16:49:
5 160912801;Report;2016-03-31T00:00:00;17:38;2016-03-31T17:38:00;
6 160912811;594;2016-03-31T00:00:00;17:42;2016-03-31T17:42:00;REP
7 160913003;Ref'd;2016-03-31T00:00:00;18:29;2016-03-31T18:29:00;G
8 160913050;Homeless Complaint;2016-03-31T00:00:00;18:43;2016-03-
9 160913056;Homeless Complaint;2016-03-31T00:00:00;18:47;2016-03-
10 160913078;Agg Assault / Adw Dv;2016-03-31T00:00:00;18:52;2016-0
11 160913103;Encampment;2016-03-31T00:00:00;18:57;2016-03-31T18:57
12 160913118;Burglary;2016-03-31T00:00:00;18:59;2016-03-31T18:59:0
13 160913148;Suspicious Person;2016-03-31T00:00:00;19:08;2016-03-3
14 160913167;Ip;2016-03-31T00:00:00;19:13;2016-03-31T19:13:00;HAN;
```




The screenshot shows a code editor with two panes. The left pane displays an XML document with employee data:

```
<employees>
  - <person id="1392">
    <name>John Smith</name>
    <dob>1974-07-25</dob>
    <start-date>2004-08-01</start-date>
    <salary currency="USD">35000</salary>
  </person>
  - <person id="1395">
    <name>Clara Tennison</name>
    <dob>1968-03-15</dob>
    <start-date>2003-05-16</start-date>
    <salary currency="USD">27000</salary>
  </person>
</employees>
```

The right pane displays a JSON object representing a terraza (terrace) location:

```
{
  "id_terraza": 7,
  "id_local": 280067128,
  "id_distrito_local": 20,
  "desc_distrito_local": "SAN BLAS-CANILLEJAS",
  "desc_barrio_local": "ROSAS",
  "clase_vial_edificio": "CALLE",
  "num_edificio": 177,
  "Cod_Postal": 28022,
  "coordenada_x_local": "448900,55",
  "coordenada_y_local": "4474755,41",
  "desc_situacion_local": "Abierto",
  "Nombre": "SR",
  "id_período_terraza": 2,
  "desc_período_terraza": "Estacional",
  "id_situacion_terraza": 1,
  "desc_situacion_terraza": "Abierta",
  "Superficie_ES": "7,2"
},
```

Jerarquía del conocimiento



Transformación del dato

- ▶ **Contextualización:** conocer el propósito del dato obtenido.
- ▶ **Categorización:** conocer la unidad de medida y los componentes del dato.
- ▶ **Cálculo:** realizar una operación matemática sobre el dato.
- ▶ **Corrección:** eliminar errores del dato.
- ▶ **Agregación:** resumir o minimizar un dato de forma más concisa.

Transformación de la información

- ▶ **Comparación:** relación entre información obtenida en distintas experiencias.
- ▶ **Repercusión:** implicación de la información en decisiones y acciones.
- ▶ **Conexión:** relación entre distintos tipos de información.
- ▶ **Conversación:** opinión de otras personas sobre la información.

Calidad del dato

- ▶ **Compleitud:** % de datos disponibles respecto a la población total que representan dichos datos.
- ▶ **Credibilidad:** fiabilidad que se le brinda al organismo que proporciona el conjunto de datos.
- ▶ **Precisión:** porcentaje de datos correctos respecto al total disponible.
- ▶ **Consistencia:** nivel con el que los datos son coherentes entre ellos.
- ▶ **Interpretabilidad:** grado en el que los datos pueden ser entendidos.

Ficheros planos: CSV

- ▶ Intercambio de información entre aplicaciones.
- ▶ La primera línea contiene los **nombres de los campos***
**opcional.*
- ▶ Cada registro se delimita por **cambio de línea (CR y LF)**.
- ▶ Los valores de cada registro están **separados por comas**.
- ▶ Los valores pueden estar entre **comillas dobles**.
- ▶ Si un valor contiene comillas, estas deben **escaparse**
“Negocio “”grande”””



Sublime Text

```
Address;City;State;AgencyId;Range;AddressType
P;100 Block Of Chilton Av;San Francisco;CA;1;;Premise Address
DA;2300 Block Of Market St;San Francisco;CA;1;;Premise Address
Lock Of Market St;San Francisco;CA;1;;Premise Address
OF 7th St;San Francisco;CA;1;;Premise Address
ant St;San Francisco;CA;1;;Intersection
nd St;San Francisco;CA;1;;Intersection
DV;Berwick Pl/harrison St;San Francisco;CA;1;;Intersection
AN;Florida St/mariposa St;San Francisco;CA;1;;Intersection
ND;100 Block Of Genebern Wy;San Francisco;CA;1;;Premise Address
Block Of Folsom St;San Francisco;CA;1;;Premise Address
ck Of Mission St;San Francisco;CA;1;;Premise Address
A;700 Block Of Eddy St;San Francisco;CA;1;;Premise Address
Harrison St;San Francisco;CA;1;;Common Location
```

Elegid un editor y
quedaos con él.

Ficheros planos: JSON (JavaScript Object Notation)

- ▶ Intercambio de información entre aplicaciones.
- ▶ **Objeto** o registro definido por conjuntos pares nombre/valor.
- ▶ Un **array** o lista ordenada de valores.
- ▶ Delimitado por { } y los pares nombre/valor separados por comas.
- ▶ Un array se delimita por [] y los valores se separan con comas.
- ▶ **Tipo de valor:** “cadena”, número, booleano, nulo (NULL), otro objeto, un array.

```
[{  
    "Nombre": "Juan",  
    "Edad": 45,  
    "Cargo": "Director"  
}, {  
    "Nombre": "Antonio",  
    "Edad": 35,  
    "Cargo": "Gestor de proyectos"  
}]
```

Ficheros planos: XML (eXtended Markup Language)

- ▶ Intercambio de información entre aplicaciones.
- ▶ Inicia con la línea: `<?xml version="1.0">`.
- ▶ Tiene solamente un elemento raíz.
- ▶ Elemento apertura `<etiqueta>` y elemento de cierre `</etiqueta>`.
- ▶ Los elementos pueden tener atributos `<etiqueta id="miEle">`.
- ▶ Contenido del elemento: texto, uno o más elementos, combinación de ambos.

```
- <employees>
  - <person id="1392">
    <name>John Smith</name>
    <dob>1974-07-25</dob>
    <start-date>2004-08-01</start-date>
    <salary currency="USD">35000</salary>
  </person>
  - <person id="1395">
    <name>Clara Tennison</name>
    <dob>1968-03-15</dob>
    <start-date>2003-05-16</start-date>
    <salary currency="USD">27000</salary>
  </person>
</employees>
```

Tratar ficheros desde Python

```
Crear un fichero JSON desde Python

In [9]: import json
data = {}
data['people'] = []
data['people'].append({
    'name': 'Maria',
    'email': 'maria@unir.net',
    'country': 'Ecuador'
})
data['people'].append({
    'name': 'Laura',
    'email': 'laura@unir.net',
    'country': 'Colombia'
})
data['people'].append({
    'name': 'Ana',
    'email': 'ana@unir.net',
    'country': 'Panamá'
})
with open('data.txt', 'w') as outfile:
    json.dump(data, outfile)

In [10]: import json
with open('data.txt') as json_file:
    data = json.load(json_file)
    for p in data['people']:
        print('Name: ' + p['name'])
        print('Email: ' + p['email'])
        print('Country: ' + p['country'])
        print('')
```



Bases de datos

- ▶ Conjunto de datos persistente utilizado por un sistema de software.
- ▶ Componentes:
 - Datos
 - Hardware
 - Software: DBMS Database Management System
 - Usuarios: programadores, usuarios finales, administradores de BD.
- ▶ Bases de datos relacionales [SQL](#).
- ▶ Bases de datos No relacionales [NoSQL](#).
- ▶ **CRUD**: Create, Read, Update and Delete



Muchas gracias por tu
atención